



universität
uulm

Institut für Datenbanken und Informationssysteme



Assessing the Effectiveness of Large Language Model Support for Generating GDPR ROPA Documentation

Master Thesis Presentation

Emilija Kastratović

- A **Record of Processing Activities (ROPA)** is the Article 30 GDPR record every organization must keep [1]: what personal data it processes, for which purposes, and on what legal basis.
- Maintaining it is **tedious and expertise-heavy**, a real burden for small companies that have no dedicated **Data Protection Officer (DPO)**.
- **LLM support** is a promising solution: it lowers the legal-knowledge barrier and drafts the document for non-experts.



Dokumentinformationen

Dokumenttitel
Mitarbeiterverwaltung (Arbeitszeit/Uhrzeit) & Parkplatzberechtigung

Organisation

Organisationenname
APOR GmbH

Rolle
Data Controller, DPO

Adresse
Münsterstraße 67, Ulm

E-Mail
mail@apor.eu

Telefon
0122345678

Vorname
A. I. Müller

Datenschutzbeauftragter
A. I. Müller

Zweck der Datenverarbeitung

Das Unternehmen verarbeitet personenbezogene Daten, um Mitarbeitende vom Eintritt bis zum Austritt zu verwalten

Erstelltes Dokument

Verzeichnis von Verarbeitungstätigkeiten (VVT)
Mitarbeiterverwaltung (Arbeitszeit/Uhrzeit) & Parkplatzberechtigung

Verantwortliche Stelle und Kontaktdaten

Mir, die APOR GmbH, fungieren als datenschutzrechtlich Verantwortliche gemäß Art. 4 Nr. 7 DSGVO für die in folgenden beschriebenen Verarbeitungstätigkeiten.

- Firmensitz: apor gmbh
- Anschrift: Münsterstraße 67
- E-Mail-Adresse: mail@apor.eu
- Telefonnummern: 0122345678
- Vertreter: A. I. Müller
- Datenschutzbeauftragter: A. I. Müller

Zwecke und Rechtsgrundlagen der Verarbeitung

2.1 Verarbeitungszwecke

Mir verarbeiten personenbezogene Daten für folgende Zwecke:

- Verwaltung von Mitarbeitenden vom Eintritt bis zum Austritt, einschließlich:
- Anlegen neuer Mitarbeitender
- Dokumentation von Arbeitszeiten
- Verwaltung von Urlaub und Abwesenheiten
- Verwaltung von Parkplatzberechtigungen für berechtigte Mitarbeitende

2.2 Rechtsgrundlagen der Verarbeitung

Mir verarbeiten personenbezogene Daten auf Grundlage folgender Rechtsgrundlagen:

PDF [Speichern als pdf](#)

The generated ROPA document

- **Mistral** as the LLM backbone (interchangeable)

Structured document and organization information

Form Mode – Checkboxes



Rechtsgrundlage ⓘ

☐ DSGVO Art. 6(1)(a) - Einwilligung

☐ DSGVO Art. 6(1)(c) - Rechtliche Verpflichtung

☐ IfSG § 28b - Infektionsschutzgesetz

☒ BDSG § 26 - Beschäftigtendatenschutz

☒ HGB § 238(1) - Buchführungspflicht

☒ DSGVO Art. 6(1)(b) - Vertrag

☐ DSGVO Art. 6(1)(f) - Berechtigte Interessen

☐ SARS-CoV-2-Arbeitsschutzverordnung

☒ HGB § 257 - Aufbewahrungspflicht

☒ AO § 147 - Steuerrechtliche Aufbewahrung

Andere Rechtsgrundlage

§ 2 Abs. 1 Arbeitszeitgesetz (ArbZG) für Arbeitszeitverwaltung; § 1 Bundesurlaubsgesetz (BUrlG) für Urlaubsverwaltung; § 3 Parkplatzordnung der APOR GmbH (interne Richtlinie zur Parkplatzaberecht

KI-Vorschlag

Datenquellen ⓘ

☐ Microsoft Office 365

☐ Microsoft Azure

☐ Google Cloud

☐ Amazon AWS

☐ LibreOffice

☐ Finanzdienstleistungen

☐ Kreditdienstleistungen

☒ Unternehmenssysteme

☐ Dokumentenverarbeitung

☒ E-Mail-Anbieter

☐ Google Workspace

☐ Videokonferenzen

☐ E-Commerce-Plattform

☐ Online-Banking

☐ Web und Intranet

☒ HR-Software

☐ Sicherheit und Compliance

☐ Andere Spezialsoftware

Andere Datenquellen

Parkplatzverwaltungssystem der APOR GmbH (interne Lösung)

KI-Vorschlag

Datenkategorien ⓘ

Es wurde(n) 4 Änderung(en) vorgenommen.

KI-Vorschlag

- **Standardized fields** → **Form**: checkboxes fit well-defined inputs.
- Laid out and **dictates what to do** → clarity and control.

Zweck der Datenverarbeitung

Uppig: DANKSACHUNG DER BILDUNGSPOLITIK - DANKSACHUNG DER BILDUNGSPOLITIK - DANKSACHUNG DER BILDUNGSPOLITIK - DANKSACHUNG DER BILDUNGSPOLITIK

Brauchen Sie Hilfe, die Formulierung zu präzisieren oder weitere Beispiele? Ich unterstütze Sie gerne!

was ist ein konkreter Vorschlag?

Für Ihre Mitarbeiterverwaltung (Arbeitszeit/Urlaub) & Parkplatzberechtigung können Sie die Zwecke so formulieren:

Die Verarbeitung personenbezogener Daten dient folgenden Zwecken:

1. **Arbeitszeit- und Urlaubsmanagement:** Erfassung und Verwaltung von Arbeitszeiten, Überstunden, Urlaubsansprüchen und -anträgen zur Einhaltung arbeitsrechtlicher Vorgaben (z. B. Arbeitszeitgesetz, Bundesurlaubsgesetz) und zur Sicherstellung einer fairen Personalplanung.
2. **Parkplatzverwaltung:** Zuweisung und Verwaltung von Parkplätzen für Mitarbeiter, um die betriebliche Infrastruktur effizient zu nutzen und interne Regelungen (z. B. Priorisierung nach Bedarf) umzusetzen.
3. **Kommunikation und Dokumentation:** Austausch mit Mitarbeitern über Urlaubsanträge, Arbeitszeitänderungen oder Parkplatzanfragen sowie die rechtssichere Archivierung dieser Daten."

Warum das funktioniert:

- **Konkret:** Jeder Punkt nennt einen klaren Zweck mit Bezug zu Ihrer Tätigkeit.
- **Rechtlich abgesichert:** Verweise auf Gesetze (z. B. Arbeitszeitgesetz) zeigen, dass die Verarbeitung notwendig ist.
- **Praktisch:** Sie decken alle relevanten Abläufe ab – von der Planung bis zur Dokumentation.

Geben Sie Ihre Nachricht ein...

Für Ihre Mitarbeiterverwaltung (Arbeitszeit/Urlaub) & Parkplatzberechtigung können Sie die Zwecke so formulieren: "Die Verarbeitung personenbezogener Daten dient folgenden Zwecken: Arbeits

- **Most transparent** mode: the user sees every step.
- But the user must **look out for everything**.

Zweck der Datenverarbeitung

Brauchen Sie Hilfe bei der Formulierung? Oder haben Sie Fragen dazu, wie detailliert die Beschreibung sein sollte? Ich unterstütze Sie gerne!

Wähle passende Zwecke der Datenverarbeitung aus

Basierend auf dem Dokumententitel und den typischen Abläufen in Unternehmen habe ich folgende **konkrete Zwecke der Datenverarbeitung** für Sie zusammengestellt:

Ich habe die Zwecke wie folgt festgelegt:

- **Verwaltung von Arbeitszeiten und Urlaub:**
Erfassung, Genehmigung und Dokumentation von Arbeitszeiten, Überstunden, Urlaubsanträgen und -kontingenten zur Einhaltung arbeitsrechtlicher Pflichten und zur Personalplanung.
- **Organisation der Parkplatznutzung:**
Verwaltung von Parkplatzberechtigungen, Zuweisung von Stellplätzen sowie ggf. Abrechnung oder Kontrolle der Nutzung zur effizienten Ressourcennutzung.

Diese Formulierung ist DSGVO-konform, da sie:

- ✓ **spezifisch** ist (keine allgemeinen Aussagen),
- ✓ **den betrieblichen Nutzen** klar benennt,
- ✓ **die Rechtsgrundlage** (z. B. Arbeitsvertrag, Betriebsvereinbarung) implizit berücksichtigt.

Geben Sie Ihre Nachricht ein...

- **Specific, free-form input** → **Chat:** open conversation fits unstructured descriptions.
- The LLM **takes over authorship** (autonomous).
- Least overhead, least direct control.

RQ1 User experience

How do varying degrees of LLM support influence novice users during ROPA document creation?



RQ2 Document quality

How do varying degrees of LLM support influence the quality of ROPA documents produced by novice users?

RQ3 Confidence–quality alignment


Is there a discrepancy between user confidence (RQ1.3) and the document quality actually achieved (RQ2.1, RQ2.2)?

Study Scenario



Sources: Study design & non-parametric analysis [3]

System Usability Score Results




Sources: System Usability Scale (SUS) [4]


Emilija Kastratović · Master Thesis Presentation

#	Item	Form	Ask	Chat
1	I think that I would like to use this system frequently.	3.52	3.22	3.22
2	I found the system unnecessarily complex.	1.64	2.25	2.12
3	I thought the system was easy to use.	4.38	4.01	3.99
4	I think I would need the support of a technical person to use this system.	1.52	1.49	1.55
5	I found the various functions in this system were well integrated.	4.00	3.67	3.64
6	I thought there was too much inconsistency in this system.	2.16	2.04	2.01
7	I would imagine that most people would learn to use this system very quickly.	4.30	4.00	4.03
8	I found the system very cumbersome to use.	1.65	2.16	2.29
9	I felt very confident using the system.	3.83	3.84	3.90
10	I needed to learn a lot of things before I could get going.	1.61	1.61	1.62

NASA R-TLX and Per-Mode Completion Time



Subscale	Form	Ask	Chat
Mental Demand	5.77	6.80	6.36
Physical Demand	2.77	3.54	3.26
Temporal Demand	4.16	4.97	5.54
Effort	5.68	6.39	6.32
Frustration	5.88	7.58	7.13
Performance (pos.)	8.71	8.68	9.39



Sources: NASA Raw Task Load Index (R-TLX) [5, 6]

Mode	Rank-1 votes	Share	Mean rank
Form	37	53.6 %	1.78
Chat	20	29.0 %	2.07
Ask	12	17.4 %	2.14

1. Form

- + speed
- + clarity
- + control
- LLM “guesses”

2. Chat

- + comfort (“LLM takes care of it”)
- LLM opacity

3. Ask

- + high transparency
- cumbersome workflow

RQ1 User experience

How do varying degrees of LLM support influence novice users during ROPA document creation?

RQ2 Document quality

How do varying degrees of LLM support influence the quality of ROPA documents produced by novice users?

RQ3 Confidence–quality alignment

Is there a discrepancy between user confidence (RQ1.3) and the document quality actually achieved (RQ2.1, RQ2.2)?

Metric	Form	Ask	Chat
BLEU	0.129	0.127	0.143
ROUGE-1	0.488	0.465	0.511
ROUGE-2	0.306	0.257	0.291
ROUGE-L	0.388	0.347	0.389
METEOR	0.412	0.365	0.390
BERTScore Precision	0.889	0.886	0.895
BERTScore Recall	0.923	0.908	0.913
BERTScore F1	0.905	0.897	0.904
SBERT (ModernBERT)	0.986	0.986	0.990

Precision–recall trade-off: favoring precision risks *omitting* important content; favoring recall adds *overhead*. Form and Chat lead on overlap metrics, Ask trails: reference-based NLP alone names no decisive winner.

Sources: BLEU [7]; ROUGE [8]; METEOR [9]; BERTScore [10]; SBERT [11]

RQ1 User experience



How do varying degrees of LLM support influence novice users during ROPA document creation?

RQ2 Document quality

How do varying degrees of LLM support influence the quality of ROPA documents produced by novice users?

RQ3 Confidence–quality alignment

Is there a discrepancy between user confidence (RQ1.3) and the document quality actually achieved (RQ2.1, RQ2.2)?



Metric	Form	Ask	Chat
Completeness	4.84	3.84	3.18
Scenario Faithfulness	1.84	2.30	2.49
Legal Correctness	3.59	3.43	3.15
Hallucination (inverse)	1.65	2.40	2.54
Overall	2.41	2.49	2.62

By the judge, Form is worst on the holistic *Overall* score while Chat is best, but Chat leads *only* there: on **Legal Correctness** (and perceived legal confidence, Item 5) the ranking flips toward Form, suggesting the autonomous LLM can read as *too benign*, fluent yet less legally precise.

Sources: Perceived AI Support (5-pt Likert); LLM-as-a-Judge evaluation template [12]

Rechtsgrundlage ⓘ

KI-Vorschlag

☐ DSGVO Art. 6(1)(a) - Einwilligung	☒ DSGVO Art. 6(1)(b) - Vertrag
☐ DSGVO Art. 6(1)(c) - Rechtliche Verpflichtung	☐ DSGVO Art. 6(1)(f) - Berechtigte Interessen
☐ IfSG § 28b - Infektionsschutzgesetz	☐ SARS-CoV-2-Arbeitsschutzverordnung
☒ BDSG § 26 - Beschäftigtendatenschutz	☒ HGB § 257 - Aufbewahrungspflicht
☒ HGB § 239(1) - Buchführungspflicht	☒ AO § 147 - Steuerrechtliche Aufbewahrung

Andere Rechtsgrundlage

§ 2 Abs. 1 Arbeitszeitgesetz (ArbZG) für Arbeitszeitverwaltung; § 1 Bundesurlaubsgesetz (BUrlG) für Urlaubsverwaltung; § 3 Parkplatzordnung der APOR GmbH (interne Richtlinie zur Parkplatzberechtigung)

Datenquellen ⓘ

KI-Vorschlag

☐ Microsoft Office 365	☒ E-Mail-Anbieter
☐ Microsoft Azure	☐ Google Workspace
☐ Google Cloud	☐ Videokonferenzen
☐ Amazon AWS	☐ E-Commerce-Plattform
☐ LibreOffice	☐ Online-Banking
☐ Finanzdienstleistungen	☐ Web und Intranet
☐ Kreditdienstleistungen	☒ HR-Software
☒ Unternehmenssysteme	☐ Sicherheit und Compliance
☐ Dokumentenverarbeitung	☐ Andere Spezialsoftware

Andere Datenquellen

Parkplatzverwaltungssystem der APOR GmbH (interne Lösung)

Datenkategorien ⓘ

KI-Vorschlag

Es wurde(n) 4 Änderung(en) vorgenommen.

Entry point for novices, but high recall comes with **overhead**: every required field is present, even content the user never actually described.

Zweck der Datenverarbeitung

Hinweis: Denken Sie an die Zwecke – auch keine Neben Zwecke wie die Kommunikation mit Praktikanten über Urlaubsanträge. Brauchen Sie Hilfe, die Formulierung zu präzisieren oder weitere Beispiele? Ich unterstütze Sie gerne!

was ist ein konkreter Vorschlag?

Für Ihre Mitarbeiterverwaltung (Arbeitszeit/Urlaub) & Parkplatzberechtigung könnten Sie die Zwecke so formulieren:
*Die Verarbeitung personenbezogener Daten dient folgenden Zwecken:

1. **Arbeitszeit- und Urlaubsmanagement:** Erfassung und Verwaltung von Arbeitszeiten, Überstunden, Urlaubsansprüchen und -anträgen zur Einhaltung arbeitsrechtlicher Vorgaben (z. B. Arbeitszeitgesetz, Bundesurlaubsgesetz) und zur Sicherstellung einer fairen Personalplanung.
2. **Parkplatzverwaltung:** Zuweisung und Verwaltung von Parkplätzen für Mitarbeiter, um die betriebliche Infrastruktur effizient zu nutzen und interne Regelungen (z. B. Priorisierung nach Bedarf) umzusetzen.
3. **Kommunikation und Dokumentation:** Austausch mit Mitarbeitern über Urlaubsanträge, Arbeitszeitänderungen oder Parkplatzanfragen sowie die rechtssichere Archivierung dieser Daten.**

Warum das funktioniert:

- **Konkret:** Jeder Punkt nennt einen klaren Zweck mit Bezug zu Ihrer Tätigkeit.
- **Rechtlich abgesichert:** Verweise auf Gesetze (z. B. Arbeitszeitgesetz) zeigen, dass die Verarbeitung notwendig ist.
- **Praktisch:** Sie decken alle relevanten Abläufe ab – von der Planung bis zur Dokumentation.

Geben Sie Ihre Nachricht ein...

Für Ihre Mitarbeiterverwaltung (Arbeitszeit/Urlaub) & Parkplatzberechtigung könnten Sie die Zwecke so formulieren: "Die Verarbeitung personenbezogener Daten dient folgenden Zwecken: Arbeits-

Ask fails the user it was built for: a novice cannot do everything alone (know what to ask). The LLM must act as a **co-author**, not wait to be asked.

Zweck der Datenverarbeitung

×

Brauchen Sie Hilfe bei der Formulierung? Oder haben Sie Fragen dazu, wie detailliert die Beschreibung sein sollte? Ich unterstütze Sie gerne!

Wähle passende Zwecke der Datenverarbeitung aus

Basierend auf dem Dokumententitel und den typischen Abläufen in Unternehmen habe ich folgende **konkrete Zwecke der Datenverarbeitung** für Sie zusammengestellt:

Ich habe die Zwecke wie folgt festgelegt:

- **Verwaltung von Arbeitszeiten und Urlaub:**
Erfassung, Genehmigung und Dokumentation von Arbeitszeiten, Überstunden, Urlaubsanträgen und -kontingenten zur Einhaltung arbeitsrechtlicher Pflichten und zur Personalplanung.
- **Organisation der Parkplatznutzung:**
Verwaltung von Parkplatzberechtigungen, Zuweisung von Stellplätzen sowie ggf. Abrechnung oder Kontrolle der Nutzung zur effizienten Ressourcensteuerung.

Diese Formulierung ist DSGVO-konform, da sie:

- ✓ **spezifisch** ist (keine allgemeinen Aussagen),
- ✓ **den betrieblichen Nutzen** klar benennt,
- ✓ **die Rechtsgrundlage** (z. B. Arbeitsvertrag, Betriebsvereinbarung) implizit berücksichtigt.

Geben Sie Ihre Nachricht ein...

➤

Chat plays too much into the user (it affirms rather than corrects) and trades completeness for grounding: **risk of omission.**


Conclusion

- **RQ1 — Less support, not more, won the experience.** Form was the most usable, the lightest on cognitive load, the most preferred, and the fastest; four instruments converged. Ask lost structurally: a novice without GDPR knowledge does not know what to ask.
- **RQ2 — Each mode trades one risk for another.** Form supports *inclusion* (every required field present, though some was never described by the user); Chat supports *precision* (grounded in the scenario, though content may be missing); Ask trails both. An incomplete ROPA is the worse legal risk; a complete-but-fabricated one the worse operational risk.
- **RQ3 — Confidence does not track quality.** Users felt most confident in the conversational modes, yet on legal correctness the judge rated those lowest; conversational LLMs default to affirming the user's framing.
- **Contribution — a content-typed assignment.** *Enumerable* sub-records (e.g. legal bases under Art 6(1)) belong in a checkbox UI; *scenario-specific* sub-records (e.g. retention periods, technical & organizational measures) belong in conversational extraction. Legal-vocabulary quality is model-side, not UI-side. Form can also serve as a novice's **entry point**, a scaffold from which to build GDPR expertise before moving to freer interaction.
- **Takeaway — redistribution, not replacement.** The LLM is a co-author, not a teacher: neither a novice nor a model alone produces a valid ROPA; the Article 30 document exists only where the two meet.


- **Breadth over depth.** The cross-stream design was needed to compare confidence against quality (RQ3), but no single thread reached full depth: Ask's mechanism and the chapter-level NLP patterns could each support a study of their own.
- **Sample profile.** Participants were **IT-leaning, chatbot-fluent students** (majority male, mid-twenties). Older, non-IT staff who actually own ROPA documentation may calibrate confidence and quality differently, and may favor Chat less than this sample did.
- **Prototype tool, fixed model.** ROPAgen is a research prototype on a single **2025 Mistral** checkpoint shared by all modes. Relative mode trade-offs should survive a model swap (they rest on the interaction surface), but the *absolute* quality figures are tied to this checkpoint and should not be extrapolated.
- **Evaluation instruments.** A **single** expert reference (checkbox-derived, slightly favoring Form on coverage) and a **single-pass LLM-as-judge** without inter-rater replication or legal-expert validation. Multi-reference scoring and a multi-model judge ensemble would strengthen both layers.
- **Quality ceiling.** No mode reached the rubric midpoint on the Overall score, so the ceiling on document quality cannot be raised by interaction redesign alone.

Detailed Data Plots


SUS Subquestion Comparison Across Modes (including Overall)




NASA-TLX Item Comparison Across Modes (including Overall)




NLP Metrics — Distribution by AI Generation Mode (Per Document)




BERT Metrics — Distribution by AI Generation Mode (Per Document)



Chapterwise NLP Metrics - Distribution by Chapter and AI Mode (Per Chapter)



BERT Metrics (Chapter)



The six ROPA chapters

(granularity of the chapter-level NLP metrics)

1. Verantwortliche Stelle und Kontaktdaten
Controller & contact details
2. Zwecke und Rechtsgrundlagen der Verarbeitung
Purposes & legal bases
3. Kategorien personenbezogener Daten und Datenquellen
Data categories & sources
4. Betroffene Personen und Empfänger
Data subjects & recipients
5. Löschfristen und Aufbewahrungsdauern
Retention & erasure periods
6. Technische und organisatorische Maßnahmen (TOM)
Technical & organizational measures

Perceived AI Support questionnaire

(6 bespoke items, 5-point Likert: 1 = strongly disagree, 5 = strongly agree)

1. The AI was helpful in creating this document.
2. The AI helped me to complete the document faster.
3. I understood why the AI suggested specific GDPR fields.
4. I trust that the AI made correct suggestions.
5. I am confident that the AI identified the correct legal basis.
6. I would use this mode again.

- [1] GDPR-info.eu. *Art. 30 GDPR — Records of processing activities*. Accessed: 2026-01-05. 2026. URL: <https://gdpr-info.eu/art-30-gdpr/>.
- [2] GDPR.eu. *What is GDPR, the EU's new data protection law?* Accessed: 2026-01-05. 2026. URL: <https://gdpr.eu/what-is-gdpr/>.
- [3] Jeff Sauro and James R. Lewis. *Quantifying the User Experience: Practical Statistics for User Research*. 2nd ed. Cambridge, MA: Morgan Kaufmann, 2016. ISBN: 978-0-12-802308-2.
- [4] John Brooke. "SUS: A 'quick and dirty' usability scale". In: *Usability Evaluation in Industry*. Ed. by Patrick W. Jordan et al. London: Taylor & Francis, 1996, pp. 189–194.
- [5] Sandra G. Hart and Lowell E. Staveland. "Development of NASA-TLX (Task Load Index): Results of Empirical and Theoretical Research". In: *Advances in Psychology* 52 (1988), pp. 139–183. DOI: 10.1016/S0166-4115(08)62386-9.
- [6] Sandra G. Hart. "NASA-Task Load Index (NASA-TLX); 20 Years Later". In: *Proceedings of the Human Factors and Ergonomics Society Annual Meeting* 50.9 (2006), pp. 904–908. DOI: 10.1177/154193120605000909.
- [7] Kishore Papineni et al. "BLEU: a Method for Automatic Evaluation of Machine Translation". In: *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*. Philadelphia, Pennsylvania, USA, 2002, pp. 311–318. DOI: 10.3115/1073083.1073135.

- [8] Chin-Yew Lin. “ROUGE: A Package for Automatic Evaluation of Summaries”. In: *Text Summarization Branches Out: Proceedings of the ACL-04 Workshop*. Barcelona, Spain: Association for Computational Linguistics, 2004, pp. 74–81.
- [9] Satanjeev Banerjee and Alon Lavie. “METEOR: An Automatic Metric for MT Evaluation with Improved Correlation with Human Judgments”. In: *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization*. Ann Arbor, Michigan: Association for Computational Linguistics, 2005, pp. 65–72.
- [10] Tianyi Zhang et al. “BERTScore: Evaluating Text Generation with BERT”. In: *Proceedings of the 8th International Conference on Learning Representations (ICLR)*. 2020. URL: <https://openreview.net/forum?id=SkeHuCVFDr>.
- [11] Nils Reimers and Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Hong Kong, China: Association for Computational Linguistics, 2019, pp. 3982–3992. DOI: 10.18653/v1/D19-1410.

- [12] Weihang Su et al. “JuDGE: Benchmarking Judgment Document Generation for Chinese Legal System”. In: *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR '25. New York, NY, USA: Association for Computing Machinery, July 13, 2025, pp. 3573–3583. ISBN: 979-8-4007-1592-1. DOI: 10.1145/3726302.3730295. URL: <https://dl.acm.org/doi/10.1145/3726302.3730295> (visited on 02/09/2026).